







### 2020 中国系统架构师大会

SYSTEM ARCHITECT CONFERENCE CHINA 2020

# 架构融合 云化共建

[live 2020年10月22日 - 24日网络直播





# 基于Kubernetes的在/离线业务混部实践

网易数帆轻舟 李岚清







### 目录

- 资源利用率现状和原因
- Kubernetes Native Feature
- 如何基于Kubernetes进行业务混部
- 落地成果







### IDC规模和成本构成

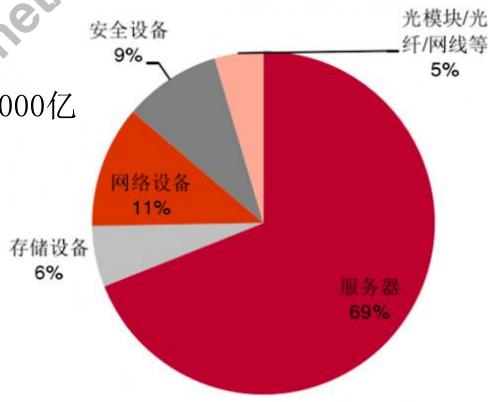


• 数字经济、互联网+、大数据

• IDC行业市场规模快速增长,预计2020年将突破2000亿

• IDC成本中,服务器成本占比达到69%

•服务器3~5年折旧

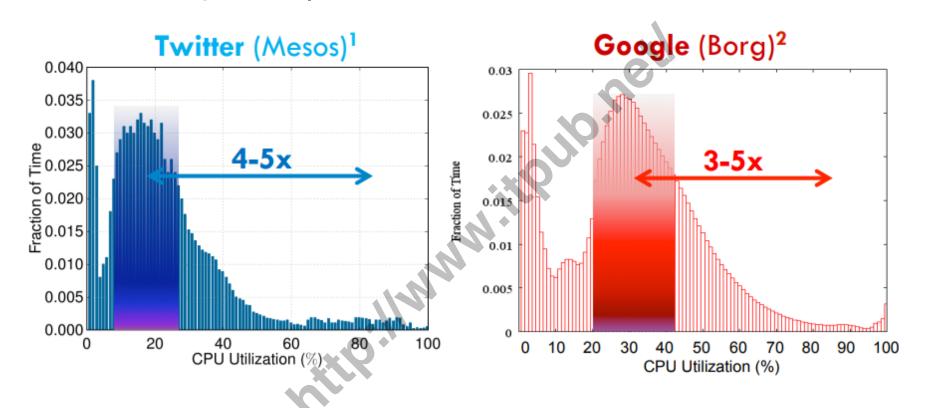






### 资源利用率现状





<sup>&</sup>lt;sup>1</sup> C. Delimitrou and C. Kozyrakis. Quasar: Resource-Efficient and QoS-Aware Cluster Management, ASPLOS 2014.





<sup>&</sup>lt;sup>2</sup> L. A. Barroso, U. Holzle. The Datacenter as a Computer, 2013.



### 在/离线业务定义

	在线业务	离线业务
举例	搜索,推荐,支付,即时通讯,游戏等	大数据批处理,AI训练,视频转 码等
时延	敏感高	不敏感
SLO	高	低
容错率	错误容忍度低	错误容忍度高
负载模型	白天负载高,夜间负载低	只要运行,负载就会一直很高

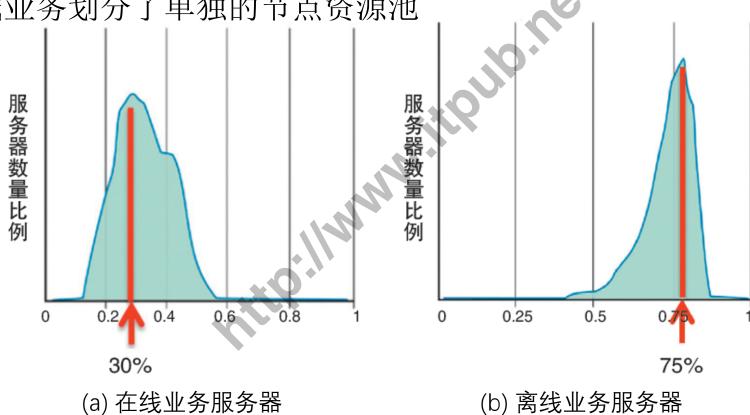




### 原因分析



• 在/离线业务划分了单独的节点资源池







### 为什么划分资源池



- 混部会带来底层共享资源(CPU、内存、网络、磁盘等)的竞争
- 在/离线服务分属不同的研发、产品团队,成本管理是分开的
- 在/离线服务使用不同的资源调度管理系统,无法统一调度

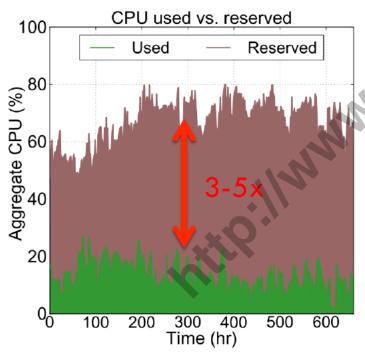


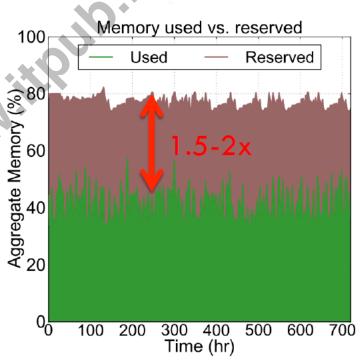


### 原因分析



• 在线业务申请了过多的资源









### 为什么申请过多资源



- 在线业务为了保证服务的稳定性,都会按照波峰申请资源
- 对于服务的资源使用情况不是特别了解,盲目申请过多的资源
- 三机房容灾部署,单副本需要能够承载所有用户请求
- 因为资源的隔离性不够,业务方希望通过申请过多资源来降低部署密度





### 原因分析

SACC 2020 主. 中国系统架构师大会 SYSTEM ARCHITECT CONFERENCE CHINA.

业务存在波峰波谷,波谷时大量资源空闲



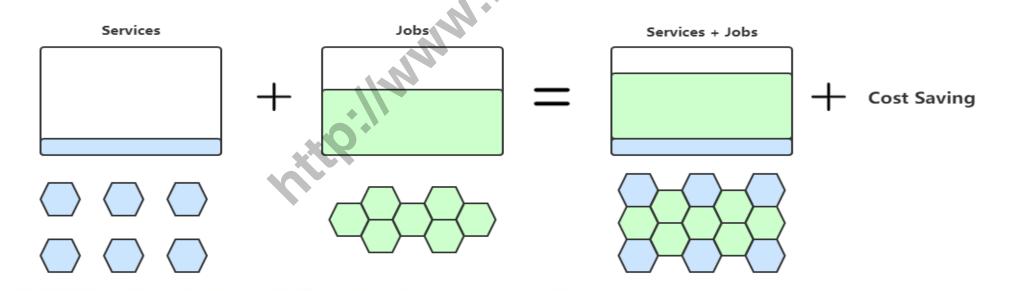




### 混部提高资源利用率



- · 离线业务不能影响在线业务的SL0
- 在线业务分配的资源是High Quality的,有资源保证
- 离线业务分配的资源是Low Quality的,可随时被在线业务抢占
- 避免离线业务饥饿





## Why Kubernetes?













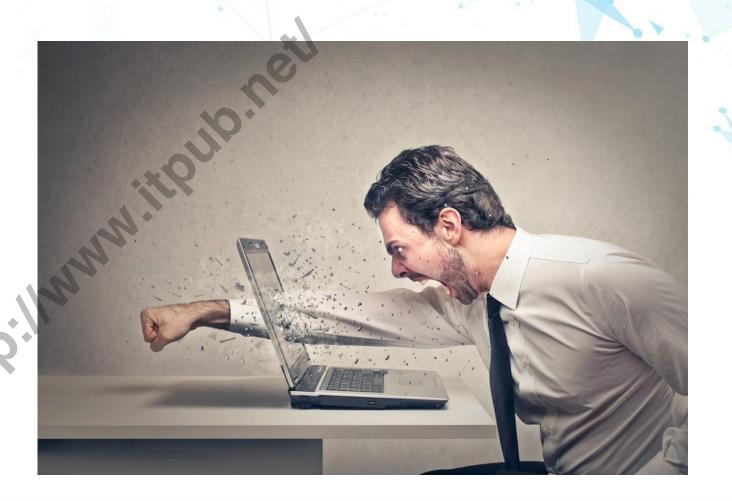




# Kubernetes存在的问题



- 静态调度
- 资源隔离性较弱





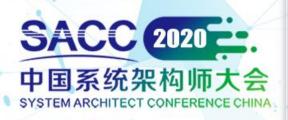


Pod Priority

- · 表示pod的重要程度,值越大优先级越高
- 调度器调度的时候会优先调度高优先级的pod
- Kubelet在驱逐过载节点的pod时,会优先驱逐低优先级的pod







#### Pod QoS

• Best Effort: cpu/memory request 和 limit都没设置

• Guaranteed: cpu/memory request=limit

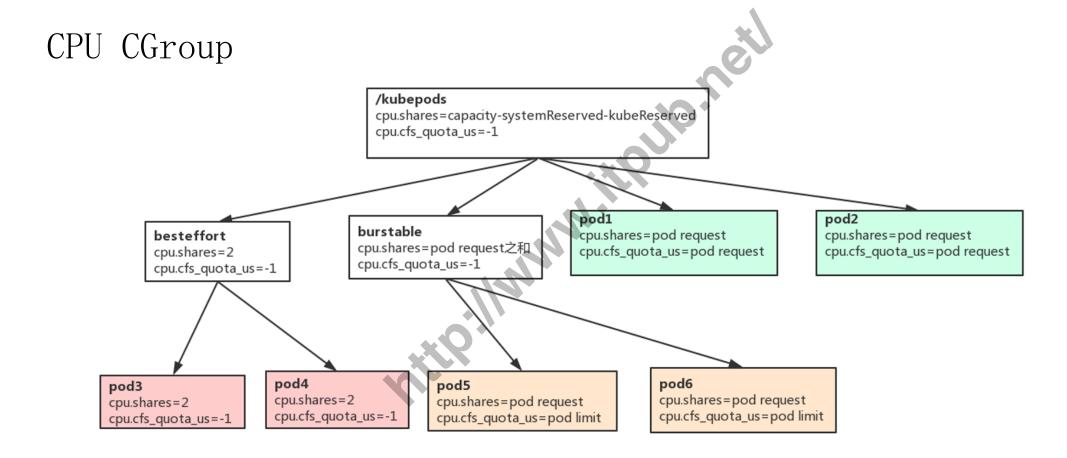
• Burstable: 其他

QoS class	oom_score_adj
Guaranteed	-998
BestEffort	1000
Burstable	min(max(2, 1000 - (1000 * memoryRequestBytes) / machineMemoryCapacityBytes), 999)







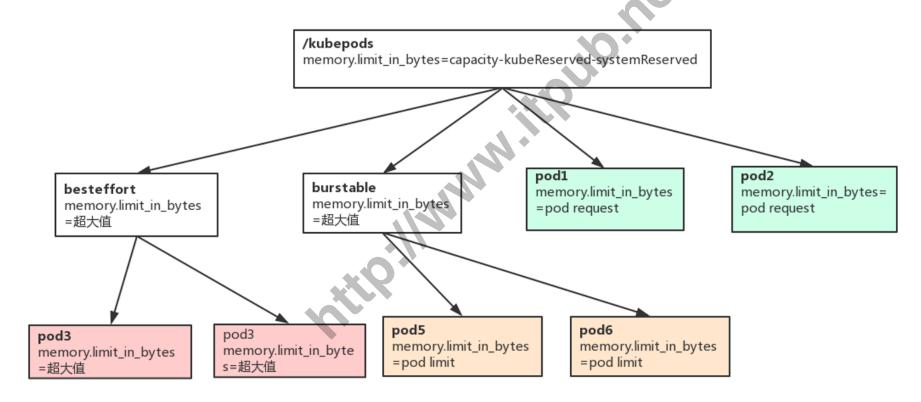








Mem CGroup



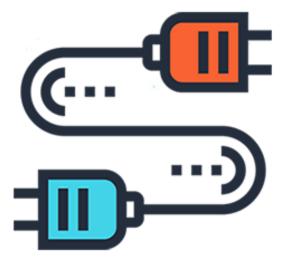






#### Extension Mechanism

- Dynamic Admission control
  - Validating Webhook
  - Mutating Webhook
- Custom Resource Definition + Operator
- Device Plugin
- Scheduler Extender



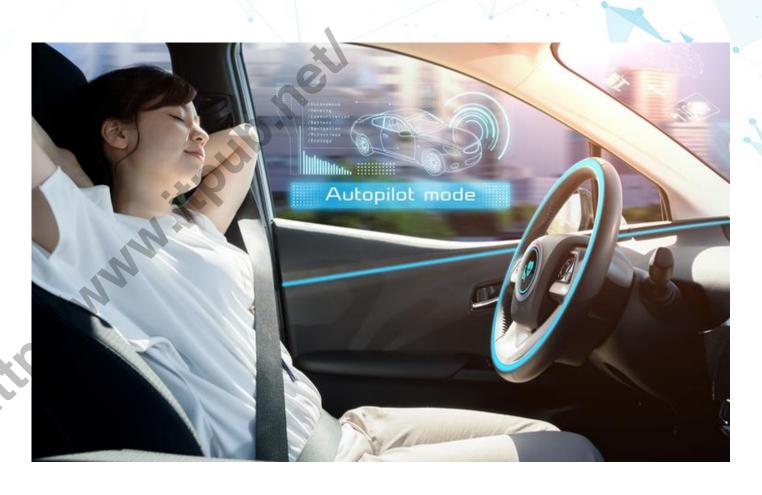




### 遵循的设计原则

SACC 2020 = 中国系统架构师大会

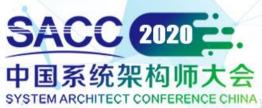
- 动态调度
- 动态资源分配和隔离
- 插件化
- 及时响应
- 可运维、可观测

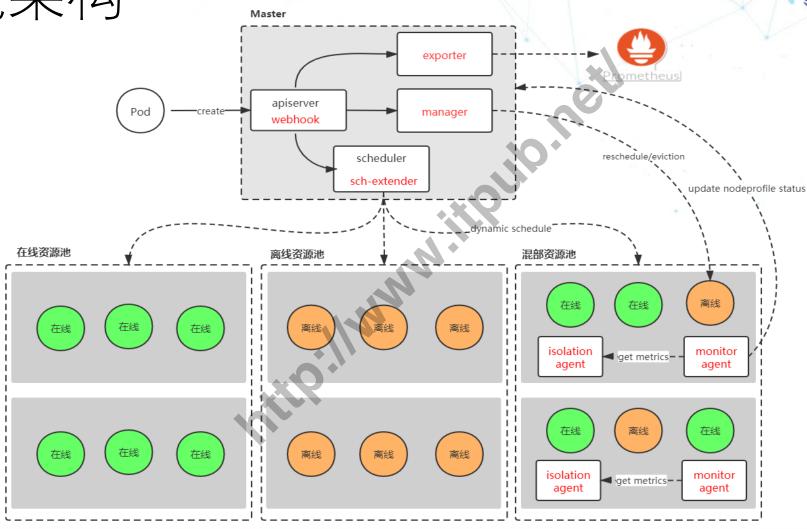






系统架构







#### Extended Resource



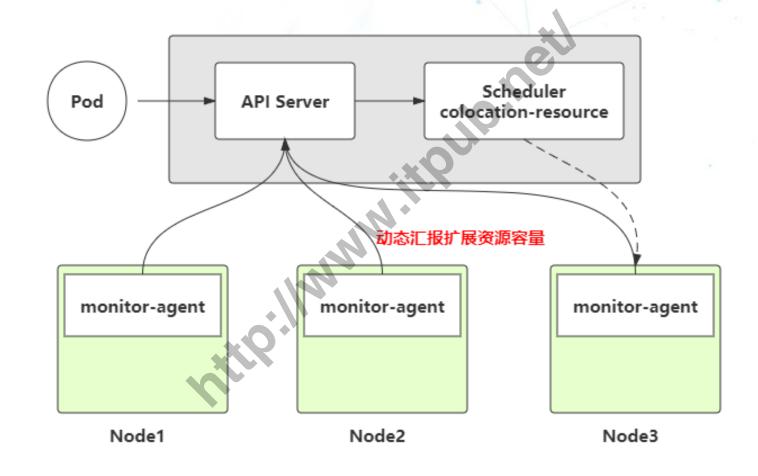
- colocation/cpu和colocation/memory
- 离线任务基于扩展资源进行调度
- 扩展资源是在线业务申请去但是目前空闲的那部分资源
- 这两个资源是Low Quality的,可能会被在线业务收回





### Resource Reclaim

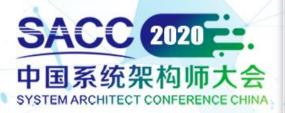








#### Webhook



```
apiVersion: v1
kind: Pod
metadata:
  name: example
                                      APIServer
Webhook
  labels:
    colocation.netease.com/workload-type: colocation-job
spec:
  resources:
    request.cpu: 2
    request.memory: 4G
```

```
apiVersion: v1
kind: Pod
metadata:
  name: example
  labels:
    colocation.netease.com/workload-type: colocation-job
  annotations:
    colocation/cpu: 2
    colocation/memory: 4G
spec:
  resources: {}
  priority: -100
  nodeSelector:
    colocation.netease.com/node-pool: colocation
```





### Dynamic Schedule

- 不能将离线任务调度到过载节点
- 优先将离线任务调度到较空闲节点

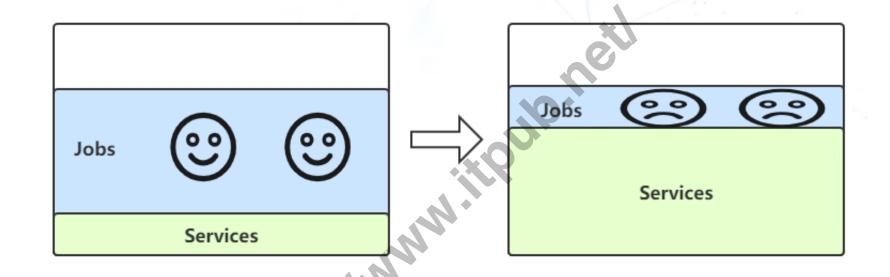






#### Reschedule





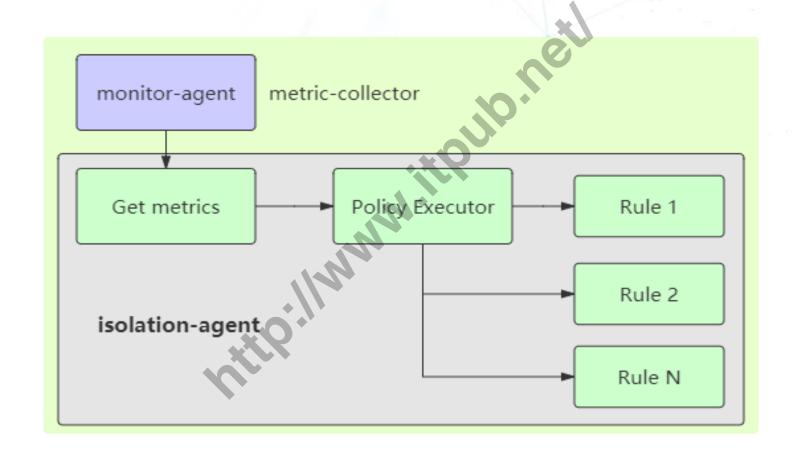
- 避免离线任务饥饿,提高执行效率
- 减少在/离线业务的资源竞争





#### Resource Isolation

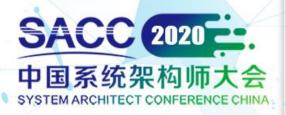








#### Resource Isolation



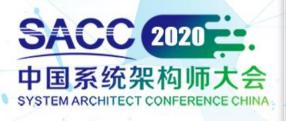
- CPU: cpu share, cfs quota, cpuset
- Memory: memory limit, MBA (Memory Bandwidth Allocation)
- Cache: CAT (Cache Allocation Technology)
- Disk: block & buffer io
- Network: separate NIC and switch





### 其他相关工作

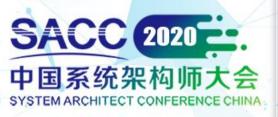
- HPA
- CronHPA
- • Resource Recommender







### 优势



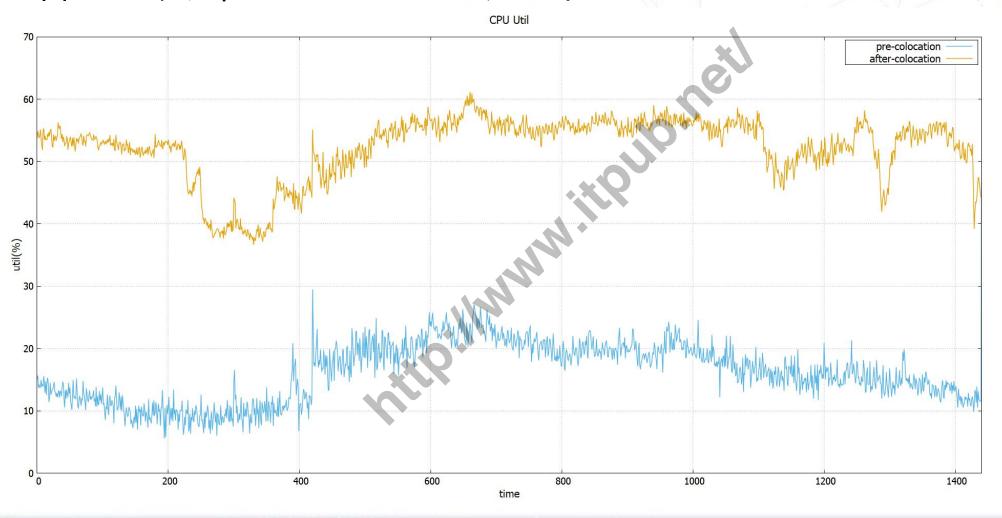
- 基于Kubernetes扩展机制开发,没有修改Kubernetes一行代码,可以方便地部署到任何一个标准的Kubernetes集群中
- 对业务不做任何假设,不需要业务进行改造,易实施落地
- 配置灵活丰富,满足多种场景的混部需求





### 落地效果 - CPU利用率









### 落地效果 - 在线业务RT



-	调用次数	失败次数	平均RT	Ms0_10	Ms10_20	Ms20_n
混部前	10.3E	0	6.59	81.99%	5.62%	12.39%
混部后	10.2E	0	6.65	81.82	5.61%	12.57%
		Wille				





### 业界研究方向



- 发现、量化、预测以及管理 性能干扰
- 基于业务的SLO和实时Metric信息,动态调整资源分配
- 基于历史数据, 预测业务的资源需求情况, 调整超售策略
- 研究分配给离线业务的Slack Resource的可用性





